

6.3: Método Montecarlo y algoritmo de Metropolis

Z es suma de $2^N = 10^{N \log 2}$ términos, la mejor supercompu puede sumar 10^{13} números/segundos. Entonces para la red $t \sim 10^{N \log 2 - 13}$, para una red de 10×10 ($N=100$): $t \sim 10^{52}$, $\sim 10^{35}$ x edad del universo.

Método de Montecarlo (Ulan, Van Neumann, Metropolis ~1950)

expect. de
calc. obs

$$\langle X \rangle = \sum_s X(s) P(s)$$

El método consiste en generar estados aleatorios $s_1, \dots, s_N$ en dist. $P(s)$ de $X(s)$ y luego promediar:

$$\langle X \rangle = \frac{1}{N} \sum_{i=1}^N X(s_i) + O\left(\frac{\sigma_X}{\sqrt{N}}\right)$$


$\frac{1}{N}$ LGN

σ_X $\sqrt{\text{Var}(X)}$

Esto sirve para calcular cualquier cosa que se pueda interpretar como un valor medio.

Ejemplo:

Área de R ?



$$f_R(x, y) = \begin{cases} 0, & \text{si } (x, y) \notin R \\ 1, & \text{si } (x, y) \in R \end{cases} \Rightarrow A_R = \int_0^1 \int_0^1 f_R(x, y) dx dy = \langle f_R \rangle \text{ según la distribución uniforme}$$

→ MC: genero puntos $(x_1, y_1), \dots, (x_N, y_N)$ dist. unif:

$$A_R \approx \frac{1}{N} \sum_{i=1}^N f_R(x_i, y_i) = \frac{N_R}{N}$$

N_R puntos que caen en R

Problema: en el caso de Ising: $P(s) = \frac{e^{-\beta H(s)}}{Z}$

Z No la conozco

⇒ ¿Cómo sampleo una distribución que no conozco (no se normaliza)? Markov Chain MC (MCMC)

Proceso estocástico

*Proceso estocástico: Secuencia de estados aleatorios $s_1, s_2, \dots$ (no tienen pq estar distribuidos igual, ni ser independientes)

↳ ejemplo: camino del borracho (S_n = posición en el paso n)

Llamamos $P_n(s)$ probabilidad del estado s en el paso n .

$$P_n(s) = P(s, n; \text{algún estado}, n-1) = \sum_{s'} P(s, n; s', n-1) = \sum_{s'} \underbrace{P(s, n | s', n-1)}_{T(s|s'): \text{Prob de transición}} P_{n-1}(s') = \sum_{s'} T(s|s') P_{n-1}(s')$$

$\hookrightarrow P_n$ Vector, T matriz $\Rightarrow P_n = T P_{n-1}$

Distribución P estacionaria (no cambia con el tiempo n) si $TP = P$.

Condición de balance detallado:

$\exists$ función ϕ / $T(s|s') = e^{-[\phi(s) - \phi(s')]} T(s'|s)$. Si se cumple, entonces: $P = \frac{e^{-\phi}}{Z}$ es estacionaria.

$Z \leftarrow$ lo que hace falta para normalizar
 $\text{den} = P(s_1, s_2, \dots, s_n) \rightarrow e^{-\phi(s_1, s_2, \dots, s_n)}$

$$(TP)(s) = \sum_{s'} T(s|s') P(s') = \sum_{s'} T(s|s') \frac{e^{-\phi(s')}}{Z} = P(s) \sum_{s'} T(s|s') \overset{=1}{=} \Rightarrow TP = P$$

Cadena de Markov

Cadena de Markov: proceso estocástico / $P(s_n, n | s_1, 1; \dots; s_{n-1}, n-1) = \underbrace{P(s_n, n | s_{n-1}, n-1)}_{T(s_n | s_{n-1})}$

no importa la historia

Una Cadena de Markov es regular si $\exists n$ / es posible ir de cualquier estado a cualquier otro en exactamente n pasos.

* Ejemplo: borracho  regular con $n=2$, pero no con $n=1$.

Teorema: para una cadena de Markov regular,
 (Demo: ver Grinstead y Snell)

* $\exists$ única distribución estacionaria P

* $\lim_{n \rightarrow \infty} P_n = P$

Una consecuencia de esto es que para una cadena de Markov regular que cumple balance detallado con función ϕ , $\lim_{n \rightarrow \infty} P_n = \frac{e^{-\phi}}{Z}$

MCMC: para samplear la distribución $\frac{e^{-\phi}}{Z}$, genero Cadena Markov, regular y que cumple BD con ϕ .

Algoritmo de Metropolis (e.m.c)

Me restringo a Ising: $\phi = \beta \mathcal{H}$. Partiendo de algún estado,

1) Elijo un sitio al azar

2) Calculo $\Delta \mathcal{H}$ que resultaría de dar vuelta ese spin

3) Si $\Delta \mathcal{H} \leq 0$, le doy vuelta. Si $\Delta \mathcal{H} > 0$, le doy vuelta la probabilidad $e^{-\beta \Delta \mathcal{H}}$

→ Obtengo nuevo estado.

Iterando: $s_1, s_2, s_3, \dots$ proceso estocástico.

* Es Markov

* Es regular: en un paso es posible flippear cualquier spin.

es posible "no hacer nada" si $\mathcal{H} < \mathcal{H}_{max}$

* Cumple BD con $\phi = \beta \mathcal{H}$:

$$T(s|s') = e^{\beta[\mathcal{H}(s) - \mathcal{H}(s')]} T(s'|s)$$

1) Si $s = s'$ esto es trivial

2) Si s difiere de s' en mas de un spin: $T(s|s') = T(s'|s) = 0$

3) Si s' difiere de s en un spin,

$$T(s'|s) \neq 0 \rightarrow \frac{T(s|s')}{T(s'|s)} = \begin{cases} e^{\beta[\mathcal{H}(s) - \mathcal{H}(s')]} & , \text{ si } \mathcal{H}(s) > \mathcal{H}(s') \\ e^{\beta[\mathcal{H}(s') - \mathcal{H}(s)]} & , \text{ si } \mathcal{H}(s) < \mathcal{H}(s') \end{cases} = e^{\beta[\mathcal{H}(s) - \mathcal{H}(s')]} \text{ para cualquiera de los casos}$$

$\uparrow$
 $T(s|s')$ y $T(s'|s)$ de flippear el spin (mirar el algoritmo)